Taller de *drivers*

Pablo Antonio

Departamento de Computación, FCEyN,
Universidad de Buenos Aires, Buenos Aires, Argentina

```
segundo@cuatrimestre:/2010$ _
```

La “forma” de Linux (1)

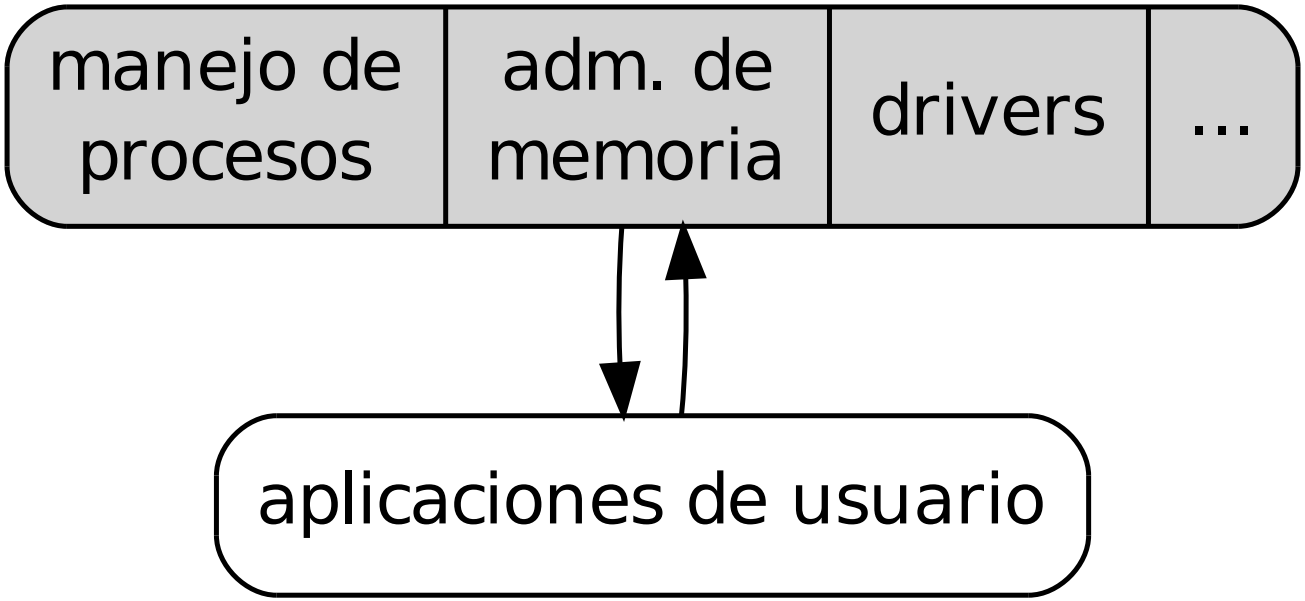

- es un kernel **monolítico**
- se ejecuta:
  - en un **único espacio de memoria**
  - enteramente en el **nivel de máximo privilegio**

La “forma” de Linux (2)

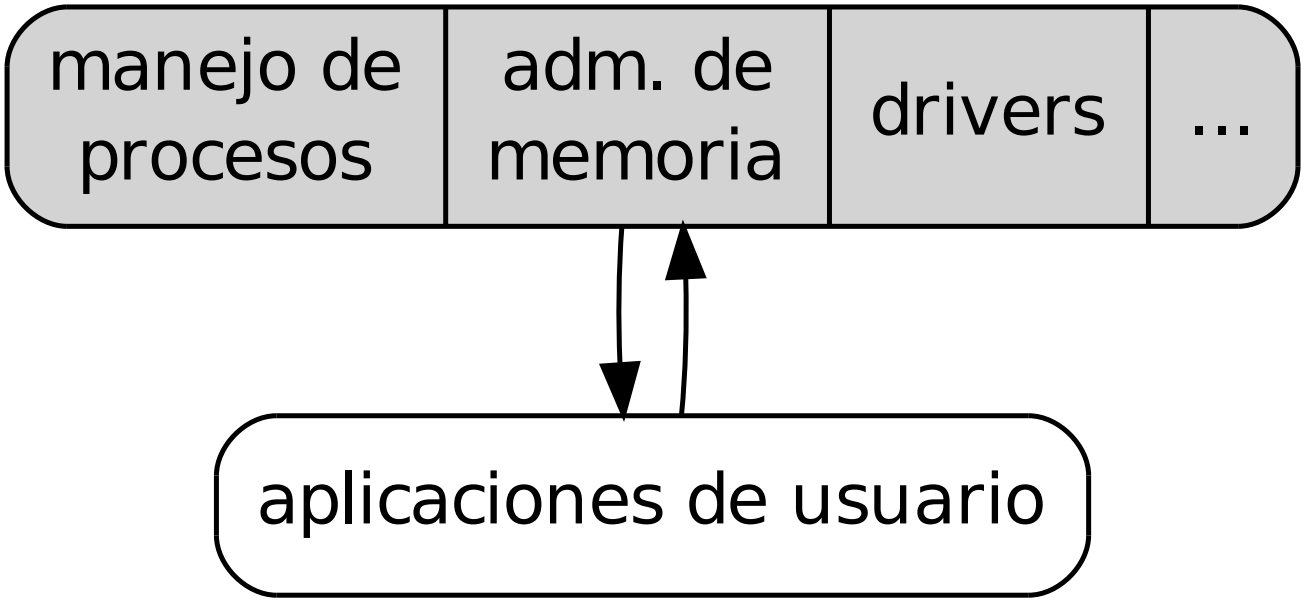

- ¿todo contenido en una gran imagen binaria?
  - ¿qué pasa si quiero agregar funcionalidad cuando ya estoy usando la máquina?
  - ¿qué pasa si incluyo funcionalidad “por las dudas”?
- Linux soporta la **carga y descarga de módulos** al kernel en tiempo de ejecución

Módulos

- un **módulo** se compone comúnmente de:
  - funciones relacionadas
  - datos
  - puntos de entrada y salida
- ¿en qué contextos podría ejecutarse el código de un módulo? (o del kernel, en general)
  1. llamada al sistema
  2. atención de interrupción
- ¿qué funcionalidades podría brindar un módulo?
- hoy vamos a escribir nuestro primer módulo...

Nuevo mundo

- estamos ejecutando en el nivel de máximo privilegio
- ¿qué pasa si hacemos un acceso indebido a memoria?
- el kernel no está enlazado a la `libc`
- hacer operaciones de punto flotante es complicado
- tenemos un stack fijo y limitado (y tenemos que compartirlo con el resto del kernel)
- hay varias fuentes de posibles condiciones de carrera

Nuestro primer módulo (1)

```
#include <linux/init.h>
#include <linux/module.h>
#include <linux/kernel.h>

static int __init hello_init(void) {
    printk(KERN_ALERT "Hola, Sistemas Operativos!\n");
    return 0;
}

static void __exit hello_exit(void) {
    printk(KERN_ALERT "Adios, mundo cruel...\n");
}

module_init(hello_init);
module_exit(hello_exit);

MODULE_LICENSE("GPL");
MODULE_AUTHOR("Pablo Antonio");
MODULE_DESCRIPTION("Una suerte de 'Hola, mundo'");
```

Nuestro primer módulo (2)

```
#include <linux/init.h>
#include <linux/module.h>
#include <linux/kernel.h>
```

- `init.h` contiene la definición de las macros `module_init()` y `module_exit()`
- `module.h` contiene varias definiciones necesarias para la gran mayoría de los módulos (por ejemplo, varios `MODULE_*`)
- `kernel.h` contiene la declaración de `printk()`

Nuestro primer módulo (3)

```
MODULE_LICENSE("GPL");
MODULE_AUTHOR("Pablo Antonio");
MODULE_DESCRIPTION("Una suerte de 'Hola, mundo'");
```

- `MODULE_LICENSE()` indica la licencia del módulo;
  - algunos valores posibles son:
    - `GPL`
    - `Dual BSD/GPL`
    - `Proprietary`
  - un módulo con una licencia propietaria "mancha" el kernel
- `MODULE_AUTHOR()` y `MODULE_DESCRIPTION()` son meramente informativos

Nuestro primer módulo (4)

```
static int __init hello_init(void) {
    printk(KERN_ALERT "Hola, Sistemas Operativos!\n");
    return 0;
}

module_init(hello_init);
```

- `static` indica que la función es local al archivo (opcional)
- `__init` le indica al kernel que la función sólo se usará al momento de la inicialización, y que puede olvidarla una vez cargado el módulo (opcional)
- `printk()` se comporta de manera similar a la función `printf()` de la *libc*, pero permite indicar niveles de prioridad:
  - `KERN_ALERT` – problema de atención inmediata
  - `KERN_INFO` – mensaje con información
  - `KERN_DEBUG` – mensaje de *debug*

Nuestro primer módulo (5)

```
static int __init hello_init(void) {
    printk(KERN_ALERT "Hola, Sistemas Operativos!\n");
    return 0;
}

module_init(hello_init);
```

- con `module_init()` se indica dónde encontrar la **función de inicialización** del módulo
- la función de inicialización es llamada:
  - al arrancar el sistema
  - al insertar el módulo
- su rol es registar recursos, inicializar hardware, reservar espacio en memoria para estructuras de datos, etc.
- si todo salió bien, tiene que devolver 0; si no, tiene que volver atrás lo que cambió y devolver algo distinto de cero

Nuestro primer módulo (6)

```
static void __exit hello_exit(void) {
    printk(KERN_ALERT "Adios, mundo cruel...\n");
}

module_exit(hello_exit);
```

- con `module_exit()` se indica dónde encontrar la **función de "limpieza"** del módulo
- la función de "limpieza" es llamada antes de quitar el módulo
- se ocupa de deshacer/limpiar todo lo que la función de inicialización y el resto del módulo usaron

Inyectando módulos al kernel

¿Cómo cargamos nuestro módulo al kernel?

- `insmod` carga el código y los datos de nuestro módulo al kernel
- el kernel usa su tabla de símbolos para enlazar todas las referencias no resueltas del módulo
- una vez cargado, se llama a su función de inicialización
- `rmmod` permite quitar el módulo del kernel si esto es posible (por ejemplo, falla si el módulo está siendo usado)
- `modprobe` es una alternativa más inteligente que `insmod` y `rmmod` (tiene en cuenta dependencias entre módulos)

Manos a la obra

1. instalar los paquetes para
   - `make`
   - `module-init-tools`
   - `linux-headers-<version>`
     (`<version>` sale de `uname -r`)
2. crear un Makefile con el siguiente contenido:

```
obj-m := hello.o
KVERSION := $(shell uname -r)

all:
    make -C /lib/modules/$(KVERSION)/build SUBDIRS=$(shell pwd) modules

clean:
    make -C /lib/modules/$(KVERSION)/build SUBDIRS=$(shell pwd) clean
```

3. ejecutar `make clean` y `make`
4. usar `insmod` y `rmmod`

Tipos de *devices*

En UNIX, comúnmente:

- **char devices**
  - pueden accederse como una tira de bytes
  - suelen no soportar *seeking*
  - se los usa directamente mediante un nodo en el filesystem
  - tienen un subtipo interesante: **misc devices**
- **block devices**
  - direccionables de a "cachos" definidos
  - suelen soportar *seeking*
  - generalmente, su nodo es montado como un filesystem
- **network devices**
  - proveen acceso a una red
  - no son accedidos a través de un nodo en el filesystem, sino de otra manera (usando sockets, por ejemplo)

Podemos ver ejemplos con `ls -l /dev`

devices y *drivers*

```
lrwxrwxrwx  1 root root           3 2010-10-08 20:00 cdrom -> sr0
...
crw-rw-rw-  1 root root      1,   8 2010-10-08 20:00 random
...
brw-rw----  1 root disk      8,   0 2010-10-08 20:00 sda
brw-rw----  1 root disk      8,   1 2010-10-08 20:00 sda1
...
```

El primer caracter de cada línea representa el tipo de archivo:

- `l` es un *symlink* (enlace simbólico)
- `c` es un *char device*
- `b` es un *block device*

Los *devices* tienen un par de números asociados:

- **major**: está asociado a un driver en particular
- **minor**: identifica a un dispositivo específico que el driver maneja

Construcción de un *char device*

Vamos a construir un *char device*.

¿Qué podría hacer nuestra función de inicialización?

1. conseguir los *device numbers* que precisemos
2. registrar las funciones de cada operación que queramos realizar sobre el *device*
3. registrar al *device* como un *char device*
4. crear un nodo en el filesystem para interactuar con nuestro módulo

Device numbers

- en el código del kernel, el par *major-minor* se representa con el tipo `dev_t`

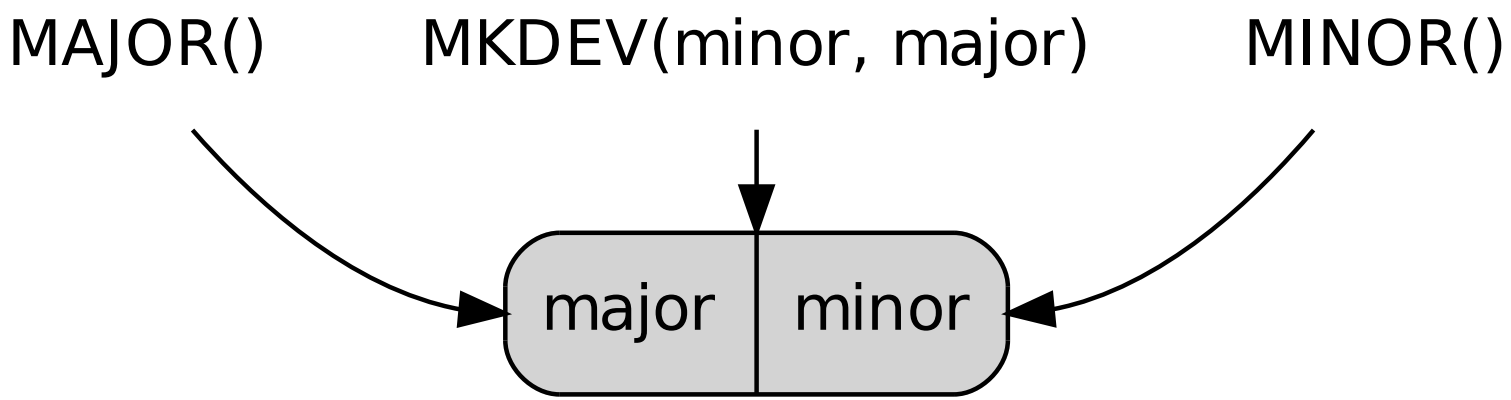

- las macros `MAJOR(dev_t dev)` y `MINOR(dev_t dev)` nos dan cada número
- `MKDEV(int major, int minor)` nos da un `dev_t` para el par de números

Reservando *device numbers*

¿Cómo reservamos los *device numbers* que necesitamos?

- pedimos un rango específico (puede ser problemático)
- pedimos al kernel que nos asigne un rango dinámicamente

Para reservarlos dinámicamente, tenemos `alloc_chrdev_region()`. Recibe:

- `dev_t *dev`: parámetro de salida
- `unsigned int firstminor`: primer *minor* a ser usado
- `unsigned int count`: cantidad de *device numbers* contiguos
- `char *name`: nombre del device asociado al rango

Para liberarlos, `unregister_chrdev_region()`. Recibe:

- `dev_t *first`
- `int count`

Las operaciones (1)

```
struct file_operations {
    struct module *owner;
    ...
    ssize_t (*read) (struct file *, char __user *, size_t, loff_t *);
    ssize_t (*write) (struct file *, const char __user *, size_t,
        loff_t *);
    ...
}
```

- ya tenemos nuestros *device numbers*, pero todavía no podemos realizar operaciones con ellos.
- la estructura `file_operations` representa las operaciones que las aplicaciones pueden realizar sobre los *devices*
- cada campo apunta a una función en nuestro módulo que se encarga de la operación, o es `NULL`
- si el campo es `NULL` tiene lugar una operación por omisión distinta para cada campo

Las operaciones (2)

```
struct file_operations {
    struct module *owner;
    ...
    ssize_t (*read) (struct file *, char __user *, size_t, loff_t *);
    ssize_t (*write) (struct file *, const char __user *, size_t,
        loff_t *);
    ...
}
```

- `owner`: un puntero al módulo "dueño" de la estructura (generalmente `THIS_MODULE`)
- `read()`: para recibir datos desde el *device*; retorna el número de bytes leídos
- `write()`: para enviar datos al *device*; retorna el número de bytes escritos

- si el puntero de `read()` o `write()` es `NULL`, se retorna `-EINVAL` al tratar de realizar la operación

La abstracción cdev (1)

- el kernel representa internamente a los *char devices* mediante la estructura `struct cdev`
- antes de que el kernel llame a nuestras operaciones, tenemos que inicializar y registrar al menos una de estas estructuras

Para inicializar, podemos:

1. pedir al kernel que dinámicamente nos reserve y otorgue una estructura, del siguiente modo:

```
struct cdev *mi_cdev = cdev_alloc();
my_cdev->ops = &mi_fops;
```

2. inicializar una estructura ya reservada usando:

```
void cdev_init(struct cdev *cdev, struct file_operations *fops);
```

En los dos casos, hay que inicializar `cdev.owner` a `THIS_MODULE`

La abstracción cdev (2)

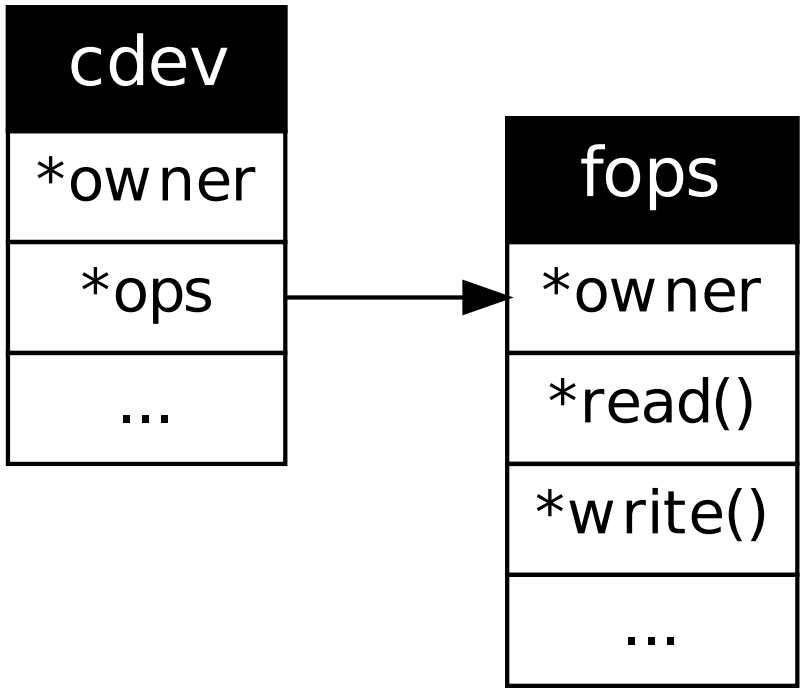

La abstracción cdev (3)

Ahora, registramos con:

```
int cdev_add(struct cdev *dev, dev_t num, unsigned int count);
```

Tener en cuenta que:

- `cdev_add()` puede fallar
- si no falló, las operaciones de nuestro módulo ya pueden ser llamadas

Para quitar al *char device* del sistema, usar:

```
void cdev_del(struct cdev *dev);
```

La abstracción cdev (4)

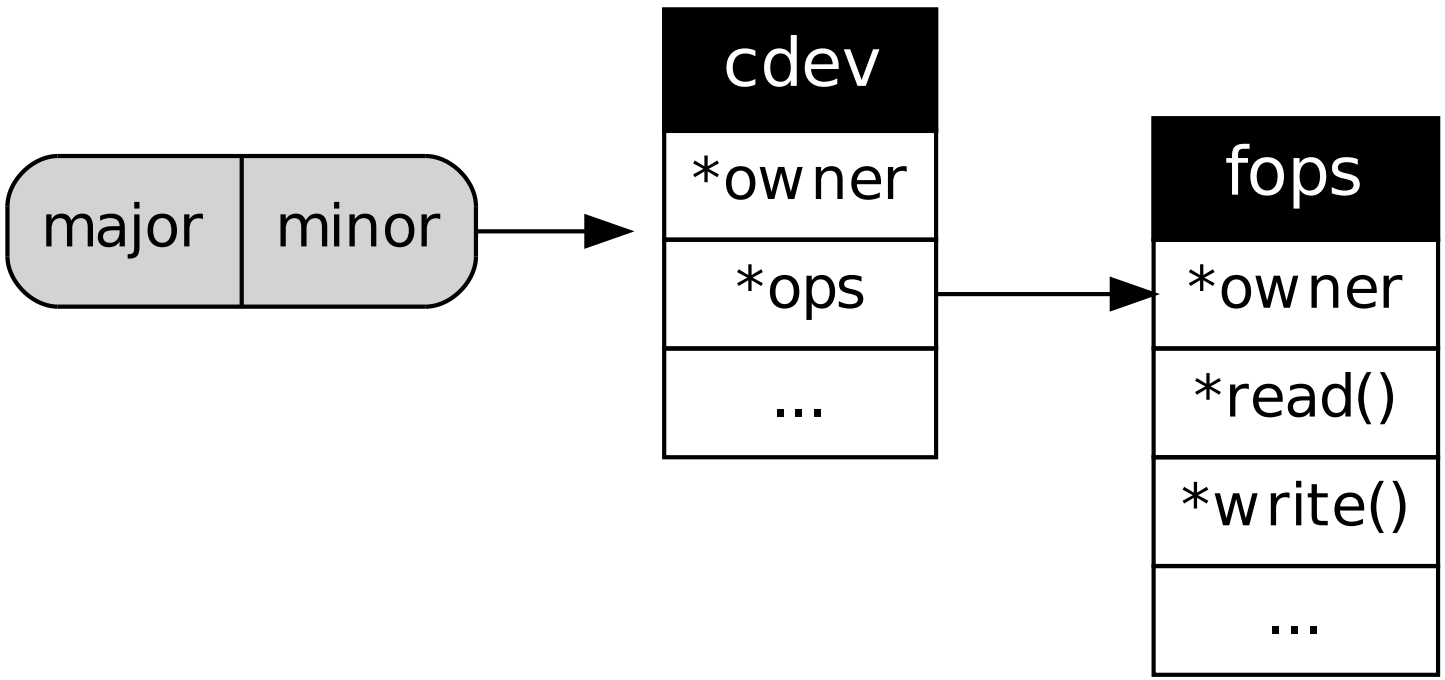

Creando nodos (1)

- una vez que el device está registrado, podemos crear los nodos en el filesystem
- sin embargo, esto debe hacerse enteramente desde espacio de usuario
- ¿por qué no desde el kernel?

"Provide mechanism, not policy"

Una distinción muy importante en el mundo UNIX:

Mechanism : las capacidades y funcionalidad que se provee

Policy : el uso que se le da a esas capacidades

Creando nodos (2)

Tenemos, a priori, dos opciones:

- crear los nodos, una vez se haya insertado el módulo, usando `mknod <nodo> c <major> <minor>` ,
- que desde el módulo se genere algún tipo de señal a alguien, en espacio de usuario, que se encargue de crear el nodo

Para lo segundo:

```
#include <linux/device.h>

static struct class *mi_class;

mi_class = class_create(THIS_MODULE, DEVICE_NAME);
device_create(mi_class, NULL, mi_devno, NULL, DEVICE_NAME);
```

```
device_destroy(mi_class, mi_devno);
class_destroy(mi_class);
```

Misc devices

¿Qué pasa si no queremos tanta flexibilidad?

- los *misc devices* son *char devices* simples que tienen varias características y una API en común
- todos comparten el *major* 10, pero pueden elegir su propio *minor*
- una llamada a `misc_register()` simplifica los pasos de:
  - pedir *device numbers*
  - crear nodos en `/dev`
  - registrar el *char device* con `cdev_init()` y `cdev_add()`

```
static struct miscdevice mi_dev = {
    MI_MINOR,
    "midriver",
    &mi_fops,
};

misc_register(&mi_dev);
```